

Research on J-Peak Extraction Method of Ballistocardiogram Signal Based on FCN and BiLSTM *

YANG Guowei¹, YIN Mingjie¹, FAN Bing^{2*}, CUI Shouyi¹, HE Yuheng¹, ZHOU Xuefang¹, BI Meihua¹, HU Miao¹

(1.School of Communication Engineering, Hangzhou Dianzi University, Hangzhou Zhejiang 310018, China;

2.Service Center for Advanced Technology, Hangzhou Dianzi University, Hangzhou Zhejiang 3110018, China)

Abstract: Ballistocardiogram (BCG) technology is one of the promising approaches in non-invasive monitoring of vital signs. Accurately extracting J peaks from BCG signals is of great importance for calculating BCG based vital sign indicators. A deep learning model based on full convolutional neural network (FCN) and bidirectional long short-term memory (BiLSTM) network is proposed to extract the J peak from BCG signals, and a J peak correction algorithm is cooperatively designed. Compared with reported typical methods, the proposed method requires less training data and has no limitation on the BCG signal length and heart rate range, so it is applicable for a wider range of practical application scenarios. To verify the feasibility and effectiveness of the proposed method, BCG signals of 22 randomly-selected subjects are collected and processed. The test results show that the proposed J-peak extraction method achieves the best recognition accuracy and better robustness, which provides an optimized solution for the J-peak extraction of the BCG signal.

Key words: ballistocardiogram; J-peak extraction; fully convolutional network; bidirectional long short-term memory network

EEACC: 7220; 7230

doi: 10.3969/j.issn.1004-1699.2025.11.007

基于 FCN 与 BiLSTM 的心冲击信号 J 峰提取方法研究 *

杨国伟¹, 尹明杰¹, 樊冰^{2*}, 崔守毅¹, 何羽恒¹, 周雪芳¹, 毕美华¹, 胡森¹

(1.杭州电子科技大学通信工程学院, 浙江 杭州 310018; 2.杭州电子科技大学前沿技术服务中心, 浙江 杭州 310018)

摘要: 心冲击图 (Ballistocardiogram, BCG) 技术在生命体征无感监护领域有良好的发展前景, 从 BCG 信号中精确提取出 J 峰对计算基于 BCG 的体征指标具有重要意义。提出了一种基于全卷积神经网络 (Full Convolutional Neural Network, FCN) 与双向长短期记忆 (Bidirectional Long Short-Term Memory, BiLSTM) 网络的深度学习模型, 用于提取 BCG 信号中的 J 峰, 并匹配设计了一种 J 峰矫正算法。对比已报道的典型方法, 所提方法训练所需的数据少、BCG 信号长度与心率范围不受限制, 适用于更加广泛的实际应用场景。为了验证所提方法的可行性、有效性, 采集了 22 名随机受试者的 BCG 信号进行处理。测试结果表明所提出的 J 峰提取方法取得了最高的识别精度、更好的鲁棒性, 为 BCG 信号 J 峰提取提供了一种优化解决方案。

关键词: 心冲击信号; J 峰提取; 全卷积神经网络; 双向长短期记忆网络

中图分类号: P391.4

文献标识码: A

文章编号: 1004-1699(2025)11-1969-09

随着老龄化人口、慢性病患者不断增长, 现有医疗监护系统越来越无法满足养老、医疗、康养的社会需求。基于心冲击图 (Ballistocardiogram, BCG) 等先进信息技术, 进行无感生命体征监测, 自主检测体征数据, 形成健康档案, 实现健康数据跟踪, 为医院诊治提供查询参考, 对老人、慢性病患者提供各类疾病的辅助诊断筛查和风险预警, 数字赋能健康生活。另一方面, 这些曾经患病、长期带病的人群已逐渐开始使用穿戴设备来监测自身关键体征指标, 但仍存在精度有限、生活不便等问题。因此, 这些问题为基于 BCG 的无感生命体征监测方案提供了前所未有的

的发展应用机遇^[1]。

BCG 是一种无创、非皮肤接触式的心血管监测手段, 通过高灵敏度传感器来拾取心脏泵血、动脉波动引起身体表面对外压力的微弱变化强度, 并将其描记成波形图^[2]。BCG 信号记录了心脏泵血引起的与心搏同步的身体表面微振动, 因此 BCG 信号可以直接分析出基本生命体征参数, 也可以间接反映一些心脏功能和血管特性, 并有可能对相关疾病进行预测、诊断或跟踪监测。

图 1 给出一个健康人的典型 BCG 信号, J 峰波动幅度相对较大, 比较显著, 是 BCG 信号用于生命

项目来源: 国家自然科学基金项目 (52175460)

收稿日期: 2023-08-05 修改日期: 2024-01-02

体征检测的主要特征,因此 J 峰提取方法是目前 BCG 信号处理的研究热点。利用 J 峰的时域特征,可以使用模板匹配方法来提取 BCG 信号的 J 峰^[3]。这种方法的提取效果与信号质量高度相关,且需要预先选定模板长度,特别对于心率变化范围较大的 BCG 信号,其检测效果会受到较大影响。模板匹配方法中需要选取的标准模板可以通过自学习算法获得,比如使用聚类分析方法提取 BCG 信号中具有高度相关性的一组曲线,将其作为心跳模板,但该方法依然容易受到受试者心率变化的影响^[4]。除了直接从 BCG 原始信号中检测 J 峰之外,还可以通过基于 J 峰频段的滤波与差分增强处理放大其特征,并设计改进的 J 峰提取算法定位心跳点,进而得到心率估计值^[5]。然而,由于 BCG 信号的非线性、非平稳性,特别当周围环境干扰严重、监测体弱老年人时,BCG 信号 J 峰会变得不明显,此时基于时域的提取方法准确性会受到较大影响。利用 BCG 信号的频域特征,也能够对其心跳周期进行提取,从而进一步对 J 峰进行提取。典型的方法就是通过对频谱的对数进行快速傅里叶变换或傅里叶逆变换来完成,即使用滑动窗口对信号进行倒谱,之后在特定频率范围内获得主频,从而获取心跳周期^[6]。这种基于频域的提取算法,其局限性在于 BCG 信号频谱中的峰值可能会被扩展和多次出现,这可能会在生命体征测量中造成偏差。




图 1 一个心跳周期的典型 BCG 信号

此外,深度学习网络也逐渐被用于 J 峰检测提取。Mai 等^[7]开发了基于 UNet 的深度学习模型用于 BCG 信号的自动心跳检测,特别是增强了低信噪比 BCG 信号的处理能力,减小了在测量过程中由于受试者测量姿势不规范和心率范围变动大带来的不利影响。此外,UNet++模型也被用于 BCG 信号的 J 峰检测,检测效果良好^[8]。然而,这两种深度学习模型只能输入与训练长度一致的 BCG 信号,大大限制了模型的实际应用场景。还有研究人员通过回归的方法,使用深度学习模型来预测 BCG 信号中的心率,这种方式不获取 J 峰的具体位置,因此无法计算更多其他生命体征指标^[9]。Hai 等^[10]受递归神

经网络在图像识别中应用的启发,提出了一种基于门控递归单元网络的心跳检测模型,将 BCG 信号的心跳检测任务建模为一个分类问题,BCG 信号片段被公式化为馈入门控递归单元网络图像来进行特征提取。和其他基于深度学习的算法类似,需要大量不同场景、人群数据集的训练,以使模型能够学习到不同形态 BCG 信号的特征,数据集采集任务繁重,模型训练周期冗长。

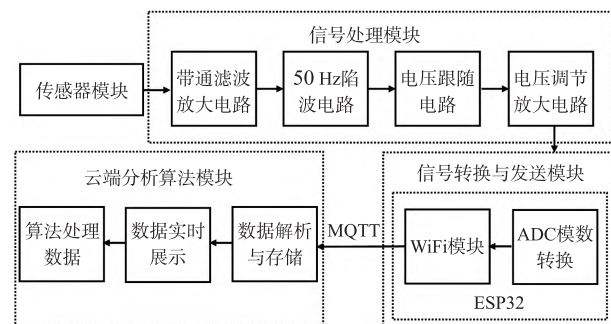
针对上述 J 峰提取、心率检测方法中存在的问题,本文设计了一种深度学习模型,可以处理不同心率范围、不同输入长度的 BCG 信号,并且无需手动选择阈值来进行模型预测。此外,本文还匹配设计了一种 J 峰矫正算法,能够对模型的预测结果进行矫正。通过这种矫正算法,即使在训练数据有限的情况下,模型也能够新的数据集上取得良好的性能。匹配的矫正算法减少了模型训练样本数量,增强了模型泛化能力,从而大大提升了本文方法的实用性。测试结果表明本文方法拥有较高的 J 峰提取准确度与鲁棒性,为进一步计算基于 BCG 信号的其他生命体征指标提供良好的技术基础。

1 材料和方法

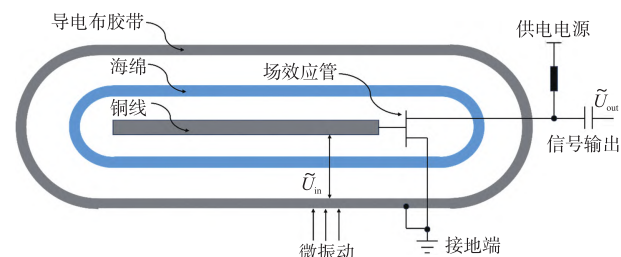
1.1 信号采集系统与测试对象

本文设计的 BCG 信号采集系统如图 2(a) 所示,主要可以分成四个模块:传感器模块、信号处理模块、信号转换与发送模块、云端分析算法模块。

系统传感器模块所使用的柔性 BCG 传感器为



(a) BCG信号采集系统框图



(b) BCG传感器结构


图 2 BCG 信号采集系统组成与 BCG 传感器结构

自主研制,本质为电容式传感器,其结构示意图如图 2(b)所示。最外层使用导电胶布作为屏蔽层,中间使用海绵作为绝缘层,内层使用铜线作为导电线,导电胶带和铜线即作为电容的两个电极。当外界微运动压力变化施加于传感器时,电容电极间距离产生变化,导致电容发生变化,从而形成反复充电、放电。场效应管的栅极和源极之间也随之产生交变电压,引起场效应管源极与漏极之间的电阻发生变化,从而在信号输出处获得与外界微运动压力相匹配的交变电压。信号从传感器中场效应管的漏极和栅极引出,并接至信号处理模块的输入端。信号处理模块主要包含带通滤波放大电路、50 Hz 陷波电路、电压跟随电路以及电压调节放大电路。带通滤波放大电路由运放单元构成,能够对传感器输出的微弱电信号进行放大,并在 0.5 Hz~40 Hz 的范围内进行带通滤波;陷波电路用于去除由电源线、周围环境等引入的 50 Hz 工频干扰;由运放单元构成的电压跟随电路能够起到阻抗匹配的作用,使得后一级的电路可以更好地工作;电压调节放大电路通过运放单元与滑动变阻器,能够对 BCG 信号的输出电压进行调节。信号转换与发送模块使用 ESP32 作为微控制单元,它能够对信号处理模块输出的电压信号进行模数转换,并由内置的 WiFi 模块通过路由器接入互联网,并使用 MQTT 协议将 BCG 信号发送至云端服务器。云端算法处理模块能够对发送至远程服务器的信号数据进行解析然后存储至数据库中,并通过平台部署的本文算法对 BCG 信号进行 J 峰提取以及进一步的生命体征指标计算。


在本次实验中,共有 22 名志愿受试者参与(男性 17 名,女性 5 名;年龄为 24.5 ± 5.2 ;身高为 (170.21 ± 7.2) cm; BMI 为 21.43 ± 4.21),所有的受试者均无已知心血管疾病,均自愿参加本次研究实验,并签署了知情同意书和承诺书。本实验数据采集过程未违反任何伦理道德准则^[11]。

1.2 测试过程


本次实验测试过程中,为了给受试者提供舒适姿势,将设计制作的心冲击传感器固定在枕头上,并将枕头放置于折叠床的一端,如图 3(a)所示。受试者处于正常躺睡姿势,对柔性 BCG 传感器基本无感知,传感器通过产生与沿其厚度方向动态作用力成比例的电荷来工作^[12]。BCG 数据采集过程中,每名受试者平躺在折叠床上,将头部枕靠在固定了 BCG 传感器的枕头上,每名受试者平躺 10 min,以记录足够时长、稳定的 BCG 信号。在本次测试实验中,BCG 信号的采样频率设定为 100 Hz。在一些预实验过程中,发



(a) BCG信号采集系统实物图



(b) ECG信号采集设备实物图



(c) 采集的BCG和ECG信号

图 3 BCG 数据采集实验

现受试者的身材会对信号质量产生一定影响,身材较瘦的受试者往往能测出较高质量的 BCG 信号。为了后续能更好地评估算法的普适性,在挑选受试者时尽量选择具有不同身材特点的人。除此之外,由于 BCG 信号本身比较微弱,只要受试者体态(如移动肢体、咳嗽、不自主抖动等)变化,BCG 信号都会受到影响,因此为了避免出现长时间连续的运动伪影,要求每位受试者在信号采集过程中尽量处于自然放松状态下的平躺。同时为了获得更大心率范围的数据,有 6 名受试者在测试之前被要求做 1 min 的深蹲起以提高心率,这些受试者采集到的 BCG 数据包含了心率由高到低变化的过程。为了给采集的 BCG 数据提供一个参考,使用一款全集成式单导联 ECG 前端 AD8232 来

采集每名受试者的 ECG 信号(见图 3(b)),BCG 和 ECG 采集通道是同步的,因此其可以作为本次研究的金标准。实验中所采集到的 BCG 与 ECG 信号示例参见图 3(c)。

1.3 方法

1.3.1 数据预处理与标签制作

首先对采集到的 BCG 信号进行预处理,主要分为带通滤波与 z-score 标准化两个步骤。其中,带通滤波的通频带为 1 Hz~10 Hz,目的是减少环境噪声并最大程度地抑制呼吸干扰^[13]。为了控制输入至神经网络的 BCG 信号幅值保持在一定范围内,以利于神经网络更好地学习到信号特征,尝试了多种信号归一化方法,包括高斯归一化、最大最小值归一化、z-score 标准化等。比较发现,使用 z-score 标准化可以使神经网络的学习效果最好。

在标签制作过程中,以 10 s 为单位对采集到的数据进行分割,因此每个样本长度为 1 000 采样点。在检查 BCG 和参考 ECG 之后,对每个 BCG 信号样本的 J 峰位置进行标记,并将每个采样点转换为相应的类别索引。在这里,J 峰的类别索引被定义为 1,而非 J 峰的类别索引为 0。为了进行 One-Hot 编码,为每个采样点创建一个元素个数等于类别数量的全零向量,将类别索引对应的向量元素设置为 1,其余元素保持为 0。针对本文 BCG 信号样本,每个采样数据点被表示为长度为 2 的向量,每个 BCG 样本标签数据大小为 $1\,000 \times 2$ 。其中,J 峰对应数据点的向量为 $[1,$

0],非 J 峰对应数据点向量均为 $[0,1]$ 。

1.3.2 FCN-BiLSTM 模型结构

受神经网络在图像分割任务中应用的启发^[14],可以将提取 BCG 信号中 J 峰的任务,看作是图像分割任务的一维版本。图像分割任务通常是对输入图像进行逐像素分类,从而获得与输入图像相同大小的概率矩阵,来完成最终的图像分割。而提取 BCG 信号中的 J 峰也需要对输入的每一个信号采样点进行分类,判断其是否为 J 峰。在全面比较不同图像分割模型后,本文使用全卷积网络(Fully Convolutional Network,FCN)作为整个模型的一个特征提取模块,用来提取 J 峰在幅值上的特征。FCN 不仅在特征提取性能方面具有优势,其内部全卷积层结构还能够接受任意长度的信号输入,这使得本文方法可以接收任意长度 BCG 信号作为输入。相比之前报道的只能输入固定长度 BCG 信号的算法模型,本文方法可以应用到更多的实际场景中。除了幅值特征之外,BCG 信号中的 J 峰还拥有很强的时序特征。在一段 BCG 信号中,相邻的两个 J 峰代表了一个心跳周期,而心跳周期的变化是具有很强的周期时序性的。借助双向长短期记忆网络(Bidirectional Long Short-Term Memory, Bi-LSTM)在跟踪时序数据上的强大能力,本文使用 Bi-LSTM 作为第二个特征提取模块,用于提取 J 峰在时序上的特征。

如图 4 所示,整个 FCN-BiLSTM 模型主要由上下两路特征提取模块构成。

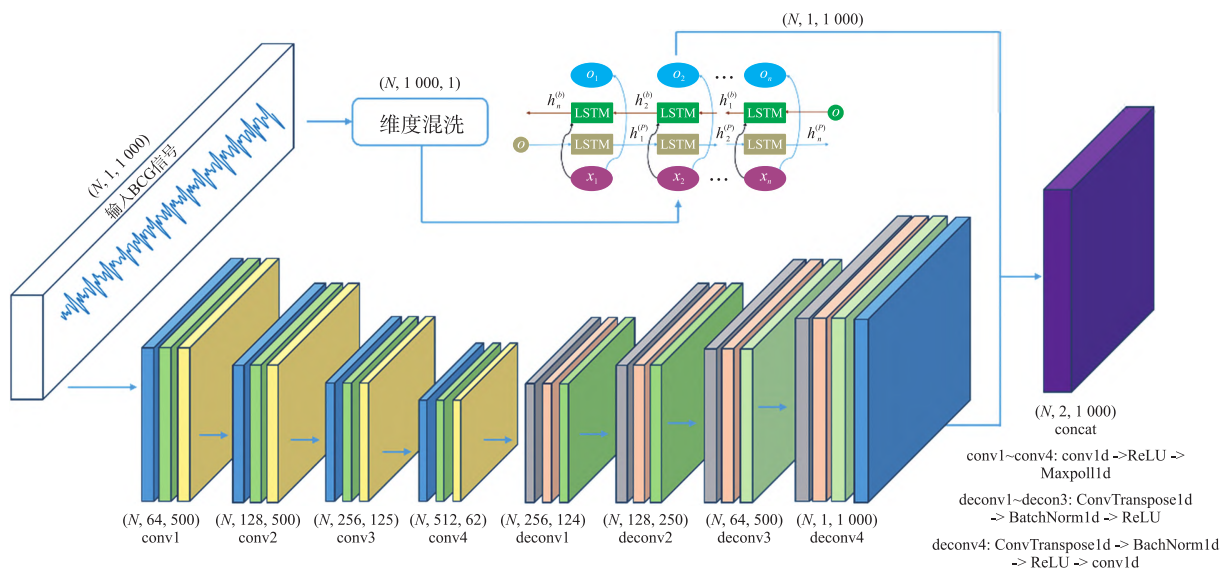


图 4 FCN-BiLSTM 网络结构

上路的特征提取模块由 BiLSTM 构成,与传统的 LSTM 网络相比,BiLSTM 善于发现连续序列的前向和后向时间特征。在所提出的深度回归网络中,

采用 BiLSTM 来提取 BCG 信号一段时间的前向和后向特征,其结构如图 5 所示。 h_n 是第 n 个时间步长的隐藏状态,它表示根据 BCG 信号的前向和后向相

关性总结的记忆信息,上标 p 和 b 分别表示 LSTM 网络前向和后向学习过程中的变量。 x_n 表示输入 BCG 信号中的第 n 个数据点, BiLSTM 的输出包含 BCG 信号的高级语义特征。下路的特征提取模块由 FCN 构成,分为编码器与解码器两个部分。其中编码器主要由卷积层、池化层构成。一个卷积层与一个池化层构成了一个下采样模块,编码器中总共有 4 个同类模块,每个模块使输入的通道数翻倍、长度减半,得到一个特征图。解码器主要由转置卷积层和跳跃连接组成,转置卷积操作将特征图进行上采样,恢复到原始输入图像的尺寸。跳跃连接将解码器中的特征图与相应编码器中的特征图进行连接,通过跳跃连接将低层特征与高层特征相融合,提升分割结果的精度。




图 5 BiLSTM 网络结构与数据输入方式

1.3.3 损失函数

在处理提取 BCG 信号 J 峰任务时,将面临样本类别不平衡的问题,因为 J 峰数量要远少于非 J 峰数量。Mai 等^[7]在打标签时将 J 峰周围的数据点同时标记为 J 峰,可能会对后续 J 峰位置精度产生影响。还有的研究未针对这一情况进行特殊处理,可能会造成模型过拟合^[8]。为了应对这个问题,本文首次选用 FocalLoss 作为训练时的损失函数。Focal-Loss 引入了困难样本系数以及类别权重系数,能够有效地处理类别不平衡问题,其计算公式为^[15]:

$$FL(p_i) = -\alpha_i (1-p_i)^\gamma \log(p_i) \quad (1)$$

式中: $(1-p_i)^\gamma$ 这一项是 FocalLoss 的困难样本系数。其中 p_i 是模型所预测的正确类别概率值,而正确类别的实际概率值为 1,因此当 p_i 越接近于 1 时,说明模型预测得越准确,相反当 p_i 越小,说明模型预测得越不准确, FocalLoss 就越倾向于将这个样本视为困难样本。只要选取合适 γ 参数,使 $(1-p_i)^\gamma$ 这一项增大,就能增大困难样本的权重,从而使模型更加专注于困难样本的学习,提高分类性能。 α_i 是类别权重系数,通过对数量较少的类别赋予较高的权重,就可以改善类别不平衡问题。因此, α_i 是一个向量,其长度等于类别的个数,用于存放各个类别的权重。

1.3.4 J 峰提取

为了进一步增强上述 FCN-BiLSTM 模型算法的

迁移能力、鲁棒性和减少模型训练数量,匹配设计了一种 J 峰矫正算法,用于对模型输出结果进行矫正。本文 J 峰提取方法的整体流程如图 6 所示。

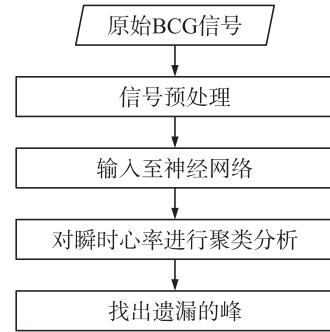


图 6 J 峰提取算法整体流程框图

整体流程的具体内容分为以下 4 个部分。

①对 BCG 信号进行带通滤波及 z-score 标准化,得到经过预处理长度为 n 的 BCG 信号 X :

$$X = \{x_1, x_2, \dots, x_k, \dots, x_{n-1}, x_n\} \quad (2)$$

式中: x_k 表示 BCG 信号 X 中第 k 个数据采样点。

②将 BCG 信号 X 输入至训练好的 FCN-BiLSTM 模型中,输出大小为 $n \times 2$ 的概率矩阵 P :

$$P = \begin{bmatrix} [p_1, 1-p_1], [p_2, 1-p_2], \dots, \\ [p_k, 1-p_k], \dots, [p_n, 1-p_n] \end{bmatrix} \quad (3)$$

模型会对 BCG 信号中每一个采样点输出一个长度为 2 的概率向量,例如对于 x_k ,模型输出 $[p_k, 1-p_k]$ 。其中 p_k 表示模型预测 x_k 是 J 峰的概率, $1-p_k$ 表示预测 x_k 不是 J 峰的概率。设定 p_k 大于 0.5,则 x_k 被预测为 J 峰,并把其坐标信息存至集合 J' 中:

$$J' = \{j'_1, j'_2, \dots, j'_k, \dots, j'_{l-1}, j'_l\} \quad (4)$$

式中: j'_k 表示模型预测出的第 k 个 J 峰坐标, l 表示集合 J' 的长度,图 7(a) 给出一个测试示例。

③遍历集合 J' ,计算出相邻坐标信息的时间间隔,计算出瞬时心率,将所有心率值存入至集合 H :

$$H = \{h_1, h_2, \dots, h_k, \dots\}, h_k = \frac{60}{j'_{k+1} - j'_k} \quad (5)$$

式中: h_k 表示由 J' 中第 $k+1$ 个与第 k 个坐标的时间间隔计算出的心率值。如图 7(b) 所示,采用顺序聚类法,将所有的心率值根据它们之间的差异程度存入不同心率集合,得到:

$$\begin{cases} H_1 = \{h_{11}, h_{12}, \dots, h_{1x}, \dots, h_{1y}, \dots\} \\ \vdots \\ H_k = \{h_{k1}, h_{k2}, \dots, h_{kx}, \dots, h_{ky}, \dots\} \\ \vdots \\ H_m = \{h_{m1}, h_{m2}, \dots, h_{mx}, \dots, h_{my}, \dots\} \end{cases} \quad (6)$$

式中: m 为心率集合的数量, h_{kx} 和 h_{ky} 分别表示第 k 个心率集合当中第 x 个和第 y 个元素。对于任意一

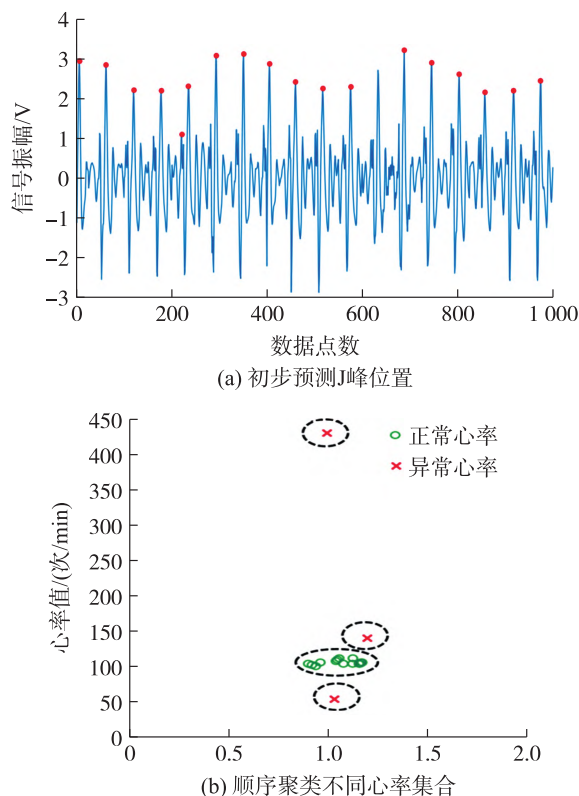


图 7 初步预测结果与心率聚类图

个心率集合来说,其内部任意两个元素之间的差异程度均在所设定的范围之内。而对于两个不同的集合,它们元素之间的差异程度则超出所设定的范围。以心率集合 H_k 为例,该集合中任意两个不同元素之间的差异程度计算方式为:

$$\Delta h = \frac{|h_{kx} - h_{ky}|}{\max(h_{kx}, h_{ky})} \quad (7)$$

式中: $\max(h_{kx}, h_{ky})$ 表示取 h_{kx} 和 h_{ky} 中数值更大者。

如图 8 所示,当在两个 J 峰之间漏取了一个、多个 J 峰时,则必定会出现异常慢心率,该处出现一个心率值比真实值低 50% 以上。当两个 J 峰之间多取了一个、多个 J 峰时,则必定会出现异常快心率,该处出现一个心率值比真实值高 1 倍以上。这两种情况下,根据式(7)计算出的异常心率与真实心率之间的差异程度均大于 0.5。因此,选取 0.5 作为一个心率集合中所有元素间差异程度的阈值。当某一心率值与 H_k 中所有元素的差异程度均小于 0.5 时,则将其归入 H_k 中。找出心率集合 H_1 至 H_m 中元素最多的集合,计算出该心率集合中所有元素的平均值,将其作为该组 BCG 信号的预估心率值 h_b ,并将该集合内心率值计算所涉及的所有 J 峰坐标信息存入集合 J 。

④如图 9(a) 所示,将集合 J 中的 J 峰坐标信息展示在对应的 BCG 波形上,并利用相邻两个位置的坐标计算心率值。根据式(7),将计算得到的心率




图 8 漏取与多取 J 峰的情况

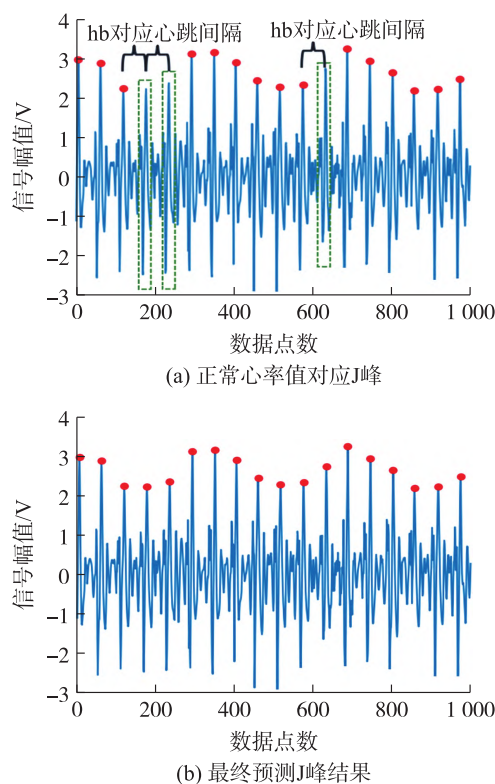


图 9 矫正过程与最终预测结果

值与 h_b 进行比较,当两者之间的差异程度大于 0.5 时,说明在这两个位置之间可能存在遗漏的 J 峰(注意集合 J 已经排除多取 J 峰数据点)。为了找到可能遗漏的 J 峰,以 h_b 对应的 J 峰间距作为单位,在两个位置坐标之间确定若干个 J 峰参考坐标。根据人体最大心率变异性范围,在每个 J 峰参考坐标前后设定搜索范围为 ± 0.2 s,如图 9(a) 中虚线框所示。在设定范围内寻找幅值最高点,将其作为遗漏的 J 峰,再将遗漏的 J 峰坐标信息补充至集合 J 中。搜索完所有遗漏 J 峰得到最终结果,如图 9(b) 所示。

2 结果

2.1 训练过程

该模型是用 Python 编写,使用 PyTorch 作为后端深度学习库,用于训练模型的计算机配有 Intel i5-13500HX CPU@2.50GHz 和 NVIDIA GeForce RTX 4060 GPU@8 GB 显存。

为了测试本文所提出的算法在跨数据集情况下的性能表现,使用开源数据集中的 BCG 数据对模型进行训练,该数据集共包括 40 名受试者的 BCG 数据,使用压电薄膜传感器以及称重传感器采集获得^[16]。同时,本文将自制 BCG 传感器采集获得的共 22 名受试者 BCG 数据作为测试数据集,用于算法性能测试。在模型训练过程中,采用 FocalLoss 损失函数和 SGD 优化器(学习率为 0.001)来更新深度学习模型的参数,训练总共持续 200 轮。

2.2 评价指标

在提取 J 峰的任务中,J 峰作为分类任务中的正类,而所有的非 J 峰作为负类。为了评价所提出方法的性能,引入以下指标。

①查准率(Precision)

查准率是针对预测结果而言的一个评价指标。在模型预测为正样本的结果中,真正是正样本所占的百分比,具体公式如下:

$$\text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}} \quad (8)$$

式中:TP 为所有正样本中,算法预测为正样本的数量,FP 为所有负样本中,算法预测为正样本的数量。具体是指真实 J 峰数量与算法预测为 J 峰数量的比值。

②召回率(Recall)

召回率是针对原始样本而言的一个评价指标。在实际为正样本中,被预测为正样本所占的百分比。具体公式如下:

$$\text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}} \quad (9)$$

式中:FN 为所有正样本中,被预测为负样本的数量。具体是指算法预测为 J 峰数量与所有真实 J 峰数量的比值。

③F1 Score

查准率和召回率在不同的场景都有其缺点。如果阈值较高,那么查准率会高,但是会漏掉很多正确数据。反之阈值较低,召回率高,但是预测查准率低。因此,普遍引入 F1 Score,具体公式如下:

$$\text{F1 Score} = \frac{2 \times \text{Precision} \times \text{Recall}}{(\text{Precision} + \text{Recall})} \quad (10)$$

2.3 综合评价与比较

在现有的研究中,大部分对所提出算法的验证工作都是基于同一个数据集进行的。文献[7]共采集了 40 名受试者的 BCG 数据,并将其划分为训练集与验证集,对提出的模型进行训练与验证。文献[11]在其采集的 13 名受试者的 BCG 数据上对提出算法进行验证。为了更好地评估算法的泛化能力,本文使用开源数据集中的 BCG 数据对模型进行训练,并将本文方法与基于模板的先驱方法^[3]、基于深度学习 UNet 模型的先驱方法^[7]在自制传感器采集的 22 名受试者的测试数据集上进行对比。为了保证对比公平性,在与基于模板的先驱方法进行对比时,每一次比较与指标计算,都会选取包含五个心跳周期以上的 BCG 信号,是为了基于模板的方法能够选取到合适的心跳周期作为算法的心跳模板。在与基于深度学习 UNet 的先驱方法进行对比时,由于其模型只能接收长度固定为 1 000 采样点的 BCG 数据,因此将每一次比较的数据长度固定为 1 000 点。

比较结果如表 1 所示,计算并统计了本文方法和两种先驱方法在 22 名受试者 BCG 数据上的查准率、召回率及 F1 Score。特别指出,表 1 给出的是经手动最优配置后基于模板的方法、基于 UNet 的方法和未经手动优化配置本文方法的比较结果。基于模板的方法在处理心率值变化范围大的 BCG 信号时,需要在计算前手动将心跳模板的长度适当调小,否则原来的心跳模板可能会涵盖一个周期以上的 BCG 信号,这会导致在匹配的过程中漏掉一些 J 峰。另外,当 J 峰出现在输入 BCG 信号的开始或末尾处,基于模板的方法天然较难识别出这些 J 峰,而本文方法和基于 UNet 的方法则可以更好地处理这种情况。在基于 UNet 的方法中,当神经网络输出与输入等长的概率向量时,需要凭借经验选取一个阈值,当 BCG 信号中某一个点所对应的概率值大于此阈值时,则将其预测为 J 峰。在实际测试过程中,不同受试者之间的 BCG 信号形态变化较大,需要手动调整阈值来提高 J 峰识别的准确度,无法自适应设定阈值。而本文方法将模型的输出概率设置为双通道,就避免了阈值选取问题,使得算法更加自动化、智能化。此外,本文方法还具备的一个优势,就是可以处理任意输入长度的 BCG 信号,使得本文方法能够适应于更多的实际应用场景。除了上述无需设置阈值和不限定信号输入长度的便利性,从表 1 数据可以看出,本文方法达到了最好的 J 峰识别准确度,其中查准率、召回率及 F1 Score 平均值分别比基于 UNet 先驱方法提高了 2.94%、2.75%、0.02,而相比基于模板匹配的先驱方法则分别提高了 5.02%、5.21%、0.05。

表 1 测试数据集上与其他算法的比较

受试者 编号	Precision/%			Recall/%			F1 Score		
	本方法	模板方法 ^[3]	UNet 方法 ^[7]	本方法	模板方法 ^[3]	UNet 方法 ^[7]	本方法	模板方法 ^[3]	UNet 方法 ^[7]
1	98.05	93.47	95.28	98.71	94.17	95.95	0.98	0.94	0.96
2	97.41	93.97	94.24	98.15	93.04	94.87	0.98	0.94	0.95
3	97.78	91.93	94.21	97.02	92.13	94.68	0.97	0.92	0.94
4	95.82	92.66	92.12	95.10	92.18	92.86	0.95	0.92	0.92
5	96.87	92.87	93.82	97.68	93.37	94.32	0.97	0.93	0.94
6	97.32	93.14	95.42	98.19	93.96	96.26	0.98	0.94	0.96
7	97.61	92.51	94.48	98.35	93.02	95.41	0.98	0.93	0.95
8	96.53	91.34	94.12	97.31	91.88	94.87	0.97	0.92	0.94
9	96.61	91.63	93.41	97.27	90.64	94.16	0.97	0.91	0.94
10	96.42	90.74	92.87	96.92	89.92	93.42	0.97	0.90	0.93
11	96.83	91.23	93.16	97.41	91.79	94.52	0.97	0.92	0.94
12	98.12	92.42	96.42	98.42	93.12	96.12	0.98	0.93	0.96
13	97.64	93.65	94.88	97.24	92.78	94.26	0.97	0.93	0.95
14	97.92	92.36	95.62	98.21	92.58	95.48	0.98	0.92	0.96
15	98.20	92.93	95.25	97.86	92.71	95.31	0.98	0.93	0.95
16	95.63	89.24	91.27	95.91	90.11	91.69	0.96	0.90	0.91
17	98.67	93.43	96.33	97.95	92.47	95.87	0.98	0.93	0.96
18	97.47	92.33	94.89	98.21	92.84	95.61	0.98	0.93	0.95
19	97.87	92.71	95.23	98.63	93.47	96.02	0.98	0.93	0.96
20	98.21	93.14	94.59	97.49	93.63	95.27	0.98	0.93	0.95
21	96.87	90.41	93.78	97.31	90.95	94.37	0.97	0.91	0.94
22	97.42	92.77	95.14	98.06	92.11	95.68	0.98	0.92	0.95
平均值	97.33	92.31	94.39	97.61	92.40	94.86	0.97	0.92	0.95
标准差	0.78	1.13	1.25	0.84	1.14	1.11	0.008	0.011	0.013

在不同受试者之间,BCG 信号的形态差异比较大。当 J 峰周围的采样数据点幅值接近 J 峰甚至超过 J 峰时,上述三种方法都会出现提取错误。对于基于模板的方法,在心跳模板中心移动到 J 峰周围时,计算出的相关系数有可能比它移动到真正 J 峰时还要高,从而提取到错误的 J 峰。对于基于 UNet 的方法,也容易在 J 峰周围错误的位置上输出一个较高的概率值,从而造成误判。对于本文方法,由于 J 峰周围的数据点幅值接近甚至超过了 J 峰幅值,也容易将这些点都判定为 J 峰。在图 10(a)情况下,匹配的 J 峰矫正算法可以将幅值小于 J 峰幅值的错误数据点纠正回来,具体参见 1.3.4 小节中③叙述的内容。而在图 10(b)情况中,当错误数据点幅值大于 J 峰幅值时就会造成误判。综合来讲,本文 J 峰提取方法的误判率比基于 UNet 的先驱方法降低了 2.94%,比基于模板匹配的先驱方法降低了 5.02%,实现了很强的鲁棒性。

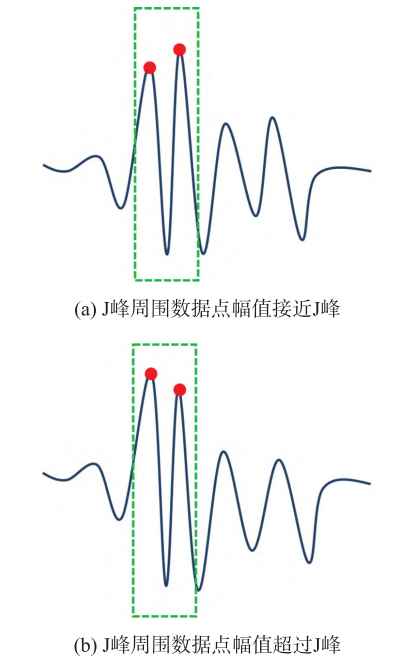


图 10 J 峰周围数据点幅值较高的情况

3 结论

本文提出了一种改进的深度学习模型 FCN-BiLSTM,能够有效地从 BCG 信号中提取 J 峰,并匹配设计了一种 J 峰矫正算法,不仅进一步提高了 J 峰提取准确性、鲁棒性,还可以减少不同类型训练数据样本、模型训练时间。本文采用自制柔性 BCG 传感器对 22 名受试者进行 BCG 信号采集,并进行信号预处理和 J 峰提取测试。与基于 UNet 的先驱方法相比,本文提出方法在查准率、召回率及 F1 Score 平均值上分别提高了 2.94%、2.75%、0.02,而相比基于模板匹配的先驱方法则分别提高了 5.02%、5.21%、0.05,这表明本文所提出的 J 峰提取方法具有最高的识别精度、更好的鲁棒性,并且无需限定 BCG 信号输入长度、无需设定预测阈值,显然可以更加便利地适用于更多实际应用场景,为推动 BCG 监测在无感生命体征监护领域的应用具有积极意义。在未来研究工作中,仍需要解决当 BCG 信号形态不够规范时(如图 10(b)情况)J 峰提取精度变差的问题,并尝试提取 BCG 信号中的多层次特征,以进一步推动 BCG 监测应用于疾病诊断方面的研究。

参考文献:

- [1] Sadek I, Biswas J, Abdulrazak B. Ballistocardiogram Signal Processing: A Review[J]. Health Information Science and Systems, 2019, 7(1): 10.
- [2] 夏建松,朱文武,杨挺. 心冲击信号研究进展及其在医学中的应用[J]. 中国医疗设备, 2021, 36(3): 168-172.
- [3] 张先文,张丽岩,丁力超,等. 基于心冲击信号的心率检测[J]. 清华大学学报(自然科学版), 2017, 57(7): 763-767.
- [4] 王炬,王田苗,栾胜,等. 基于自学习算法的 BCG 信号处理方法[J]. 传感器与微系统, 2018, 37(4): 41-43, 47.
- [5] 郑小涵,朱岩,杨越琪,等. 基于心冲击信号的心率检测方法[J]. 中国医学物理学杂志, 2021, 38(11): 1405-1411.
- [6] 谢丽君,张加宏,周炳宇,等. 基于 PVDF 压电电缆的心冲击信号采集与自适应处理方法研究[J]. 电子器件, 2020, 43(4): 841-848.
- [7] Mai Y, Chen Z, Yu B, et al. Non-contact Heartbeat Detection Based on Ballistocardiogram Using UNet and Bidirectional Long Short-Term Memory[J]. IEEE Journal of Biomedical and Health Informatics, 2022, 26(8): 3720-3730.
- [8] Zhou T, Men S, Liang J, et al. 1D U-NET++: an Effective Method for Ballistocardiogram J-peak Detection[J]. Journal of Mechanics in Medicine and Biology, 2021, 21(10): 2140058.
- [9] Jiao C, Chen C, Gou S, et al. Non-Invasive Heart Rate Estimation From Ballistocardiograms Using Bidirectional LSTM Regression[J]. IEEE Journal of Biomedical and Health Informatics, 2021, 25(9): 3396-3407.
- [10] Hai D, Chen C, Yi R H, et al. Heartbeat Detection and Rate Estimation from Ballistocardiograms Using the Gated Recurrent Unit Network[C]//2020 42nd Annual International Conference of the IEEE Engineering in Medicine and Biology Society (EMBC), Montreal, QC, Canada, IEEE, 2020: 451-454.
- [11] 任彧,刘稳,高志刚. 一种改进的用于心率估计的峰值提取方法[J]. 生物医学工程学杂志, 2019, 36(5): 834-840.
- [12] Brueser C, Diesel J, Zink M D H, et al. Automatic Detection of Atrial Fibrillation in Cardiac Vibration Signals[J]. IEEE Journal of Biomedical and Health Informatics, 2013, 17(1): 162-171.
- [13] 孟辉,张加宏,李敏,等. 基于 IPSO-BP 神经网络与 BCG 信号的冠心病预测分类研究[J]. 传感技术学报, 2020, 33(10): 1379-1385.
- [14] Long J, Shelhamer E, Darrell T. Fully Convolutional Networks for Semantic Segmentation[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2017, 39(4): 640-651.
- [15] Lin T Y, Goyal P, Girshick R, et al. Focal Loss for Dense Object Detection[C]//2017 IEEE International Conference on Computer Vision (ICCV), Venice, Italy, IEEE, 2017: 2999-3007.
- [16] Carlson C, Turpin V R, Suliman A, et al. Bed-Based Ballistocardiography Dataset[DB/OL]. New York, NY, USA: IEEE Dataport, 2020 (2020-12-30). <https://iee-dataport.org/open-access/bed-based-ballistocardiography-dataset>.



杨国伟(1984—),男,博士,副教授。主要研究方向:生物电信号处理, guowei.yang@hdu.edu.cn;



樊冰(1979—),女,副研究员。主要研究方向:物联网技术, fanbing@hdu.edu.cn。